FREEDOM BROKER · CQA HACKATHON · КОМАНДА KAIRA

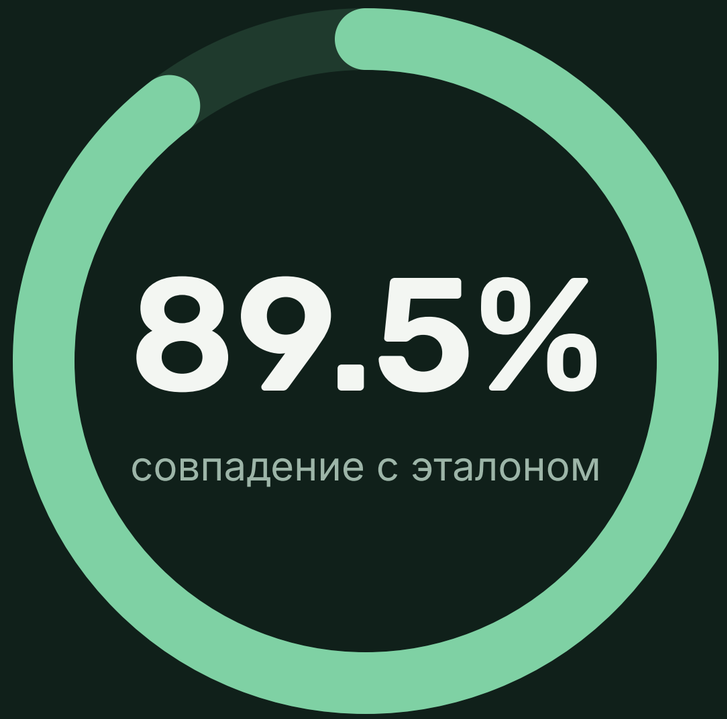
Clarity

ИИ проверяет каждый диалог оператора — и показывает доказательства

RU · KZ · EN

чаты и звонки

апелляции



Задача: оценить оператора по 8 критериям

Почему поменялся тариф?

бот → передал оператору

Здравствуйте, я Тимур. Где вы сравнивали тарифы?

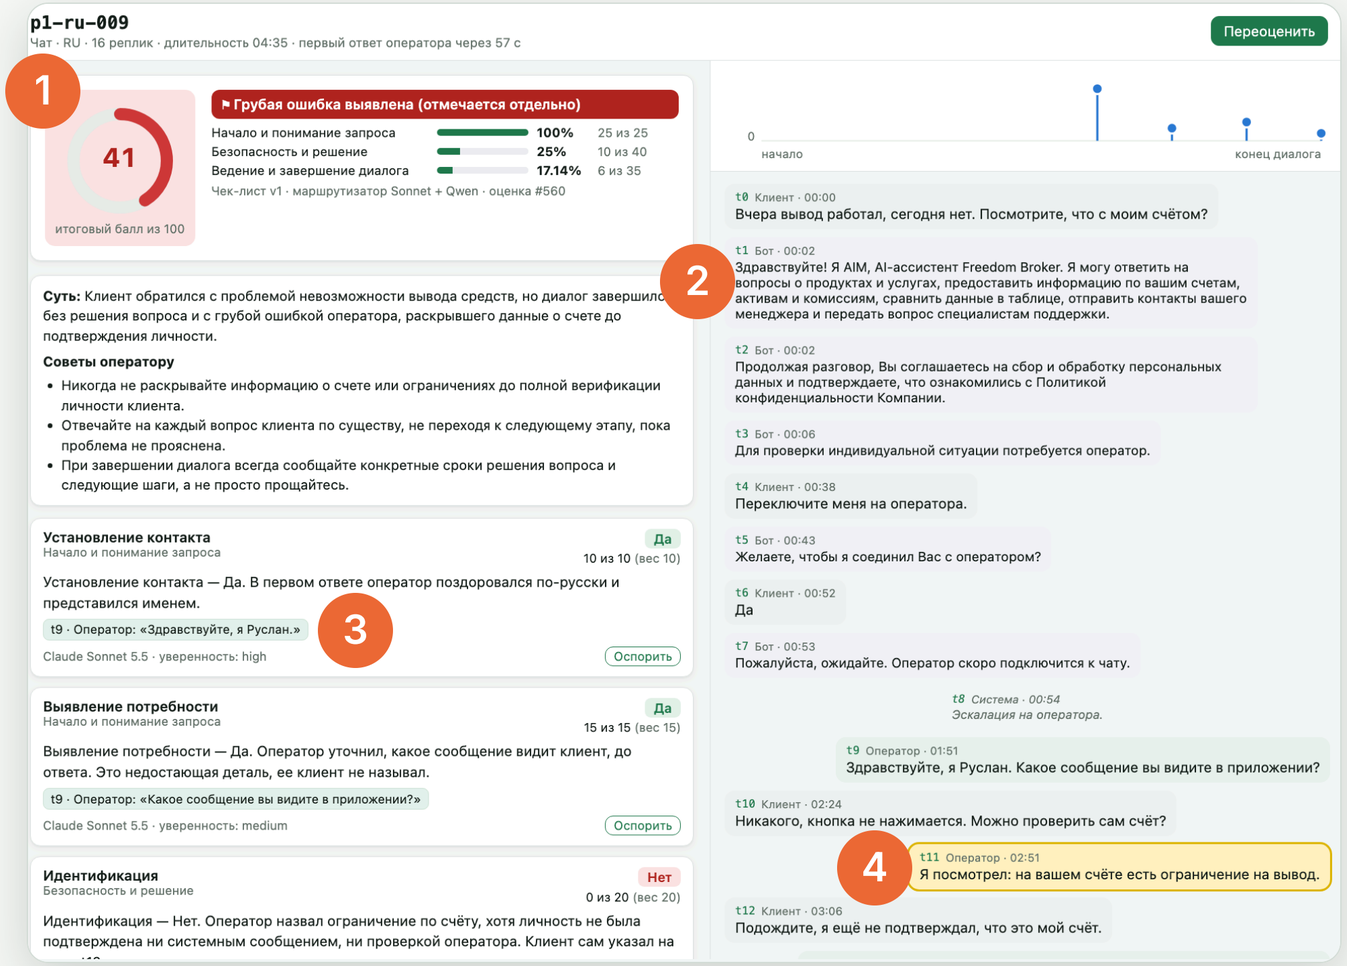
В старом отчёте и на сайте.

Если вопрос останется — напишите. До свидания!



Установление контакта	10
Выявление потребности	15
Идентификация	20
Консультация	0–20
Эмпатия	15
Ведение диалога	0–10
Завершение	5
Грубые ошибки	флаг

Каждая оценка — с доказательством



1. Итог по правилам чек-листа и флаг грубой ошибки
2. Суть диалога и советы оператору
3. Дословная цитата под каждой оценкой
4. Клик — и нужная реплика подсвечена

Модель указывает — код проверяет и считает



Диалог

RU · KZ · EN, чат или звонок

Модель

ответ и цитата по каждому критерию

Проверка

цитата дословно есть в реплике

Баллы

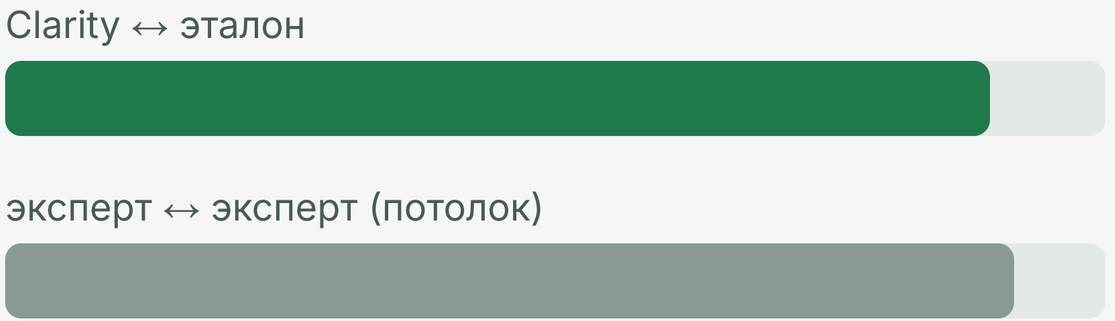
веса, N/A, секции — только код

Апелляция → решение проверяющего → итог пересчитан

Почти как второй эксперт

89.5%

ответов совпадают с эталонной разметкой

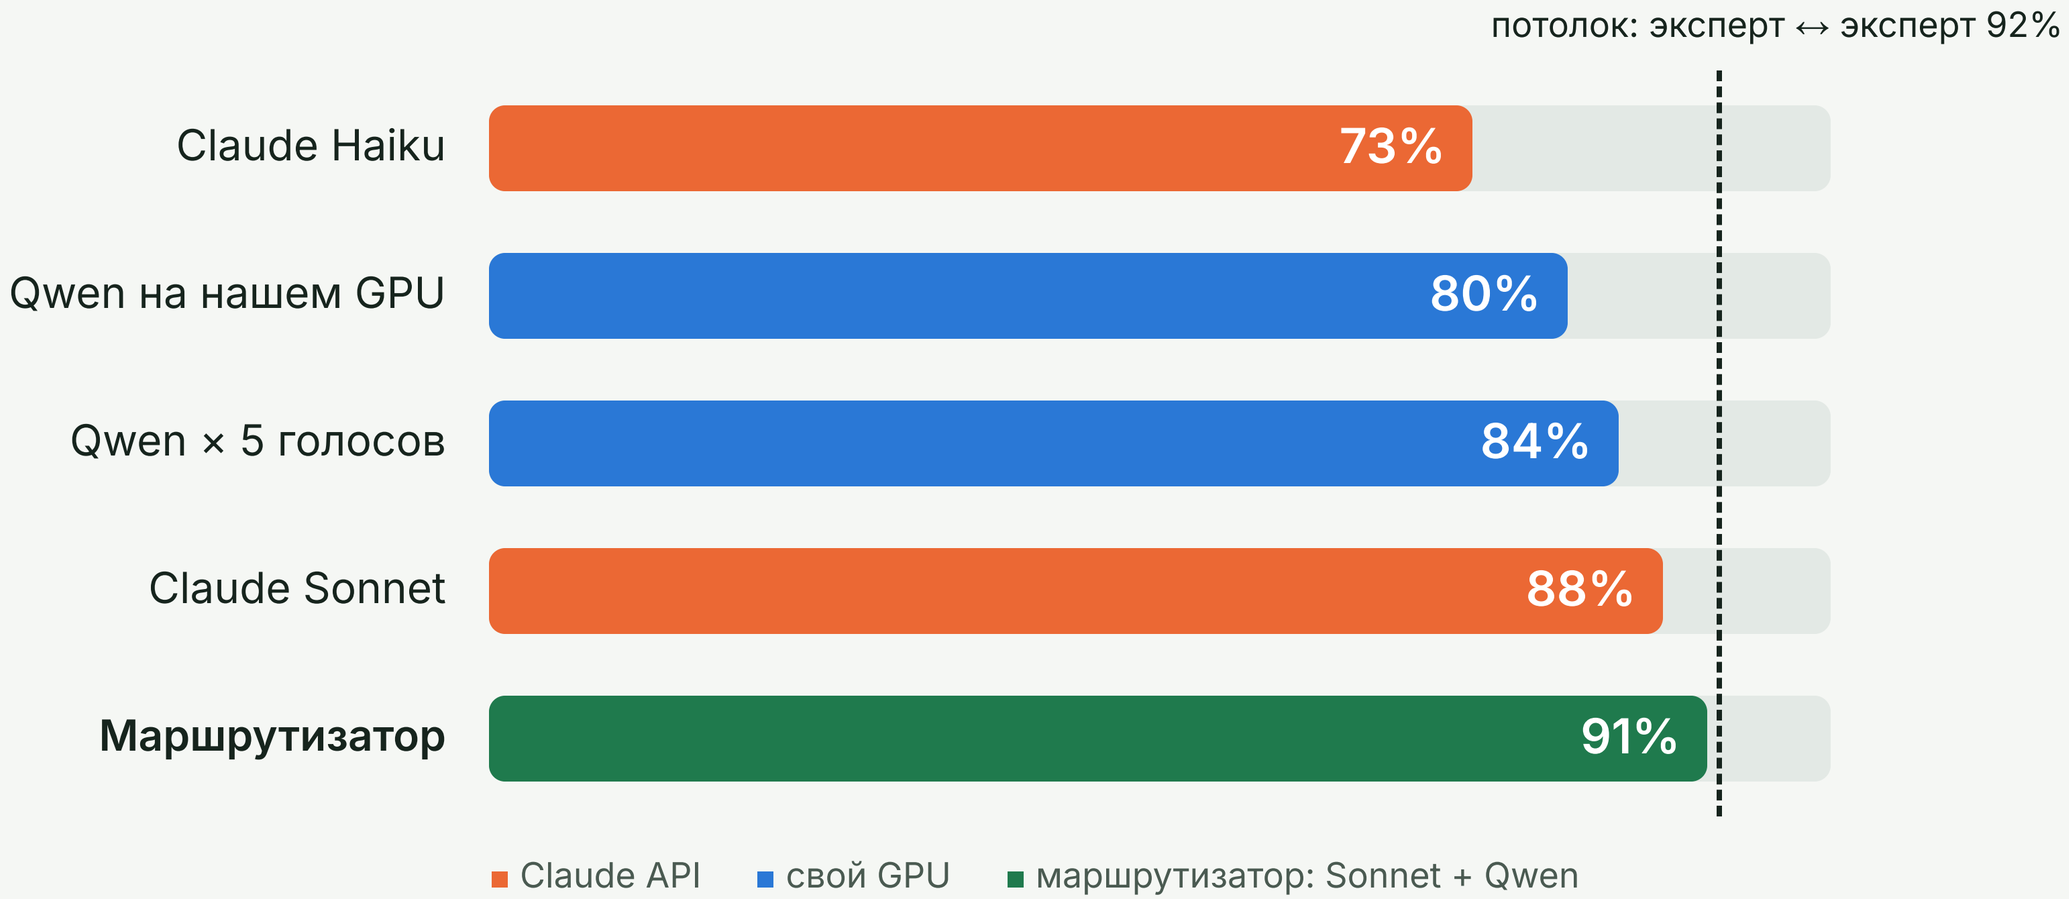


7 / 7
грубых ошибок, 0 ложных

±7
баллов — ошибка итога из 100

Эталон: 44 диалога DEV × 8 критериев (RU, KZ, EN, звонки). 95% доверительный интервал: 85–94%. Две независимые разметки совпадают на 91.7%.

26 вариантов — выбрали лучший



Точность на отложенной половине эталона; способ выбирали только на другой половине. Не помогли: подвопросы, критерий на запрос, жюри моделей, прецеденты в промпте.

Каждый критерий — своей модели

точность на эталоне	Claude Sonnet	Qwen × 5 (GPU)
Контакт	**98%**	96%
Потребность	**93%**	73%
Идентификация	**100%**	93%
Консультация	66%	**77%**
Эмпатия	86%	**96%**
Ведение диалога	61%	**75%**
Завершение	**91%**	75%
Грубые ошибки	**100%**	98%

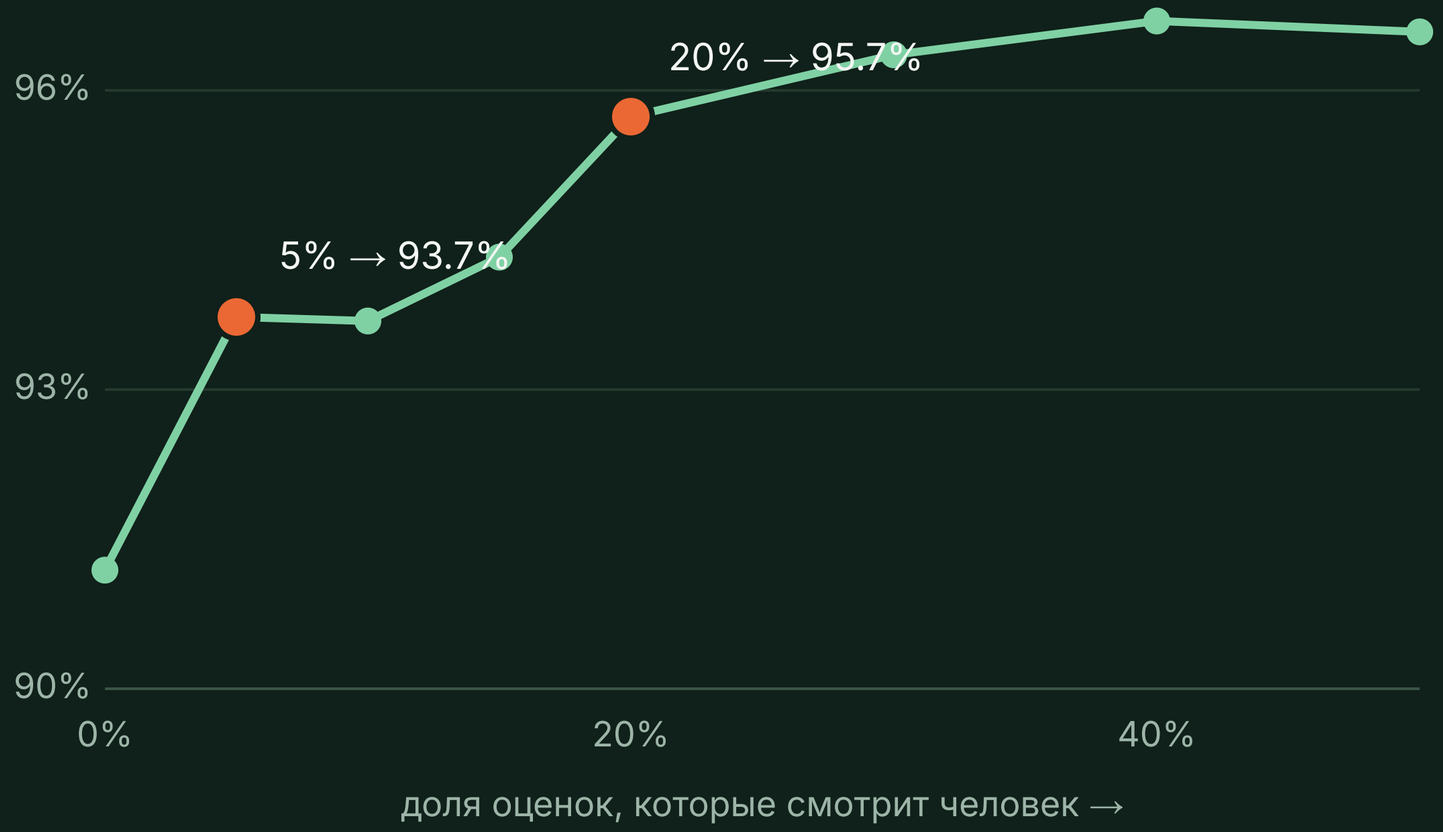
Sonnet — правила и факты

Qwen × 5 — шкалы и тон

4.7

ошибка итога вместо 8.9 у одного Sonnet

Человек смотрит только сомнительное



1/3

всех ошибок ловит проверка 5% самых неуверенных оценок

81%

решений — автоматически, с гарантией точности ≥ 90% (факт: 92.8%)

Где ещё ошибаемся — и что делаем



Шкалы: 15 из 24 — соседняя ступень

граница спорная и у людей → калибровка

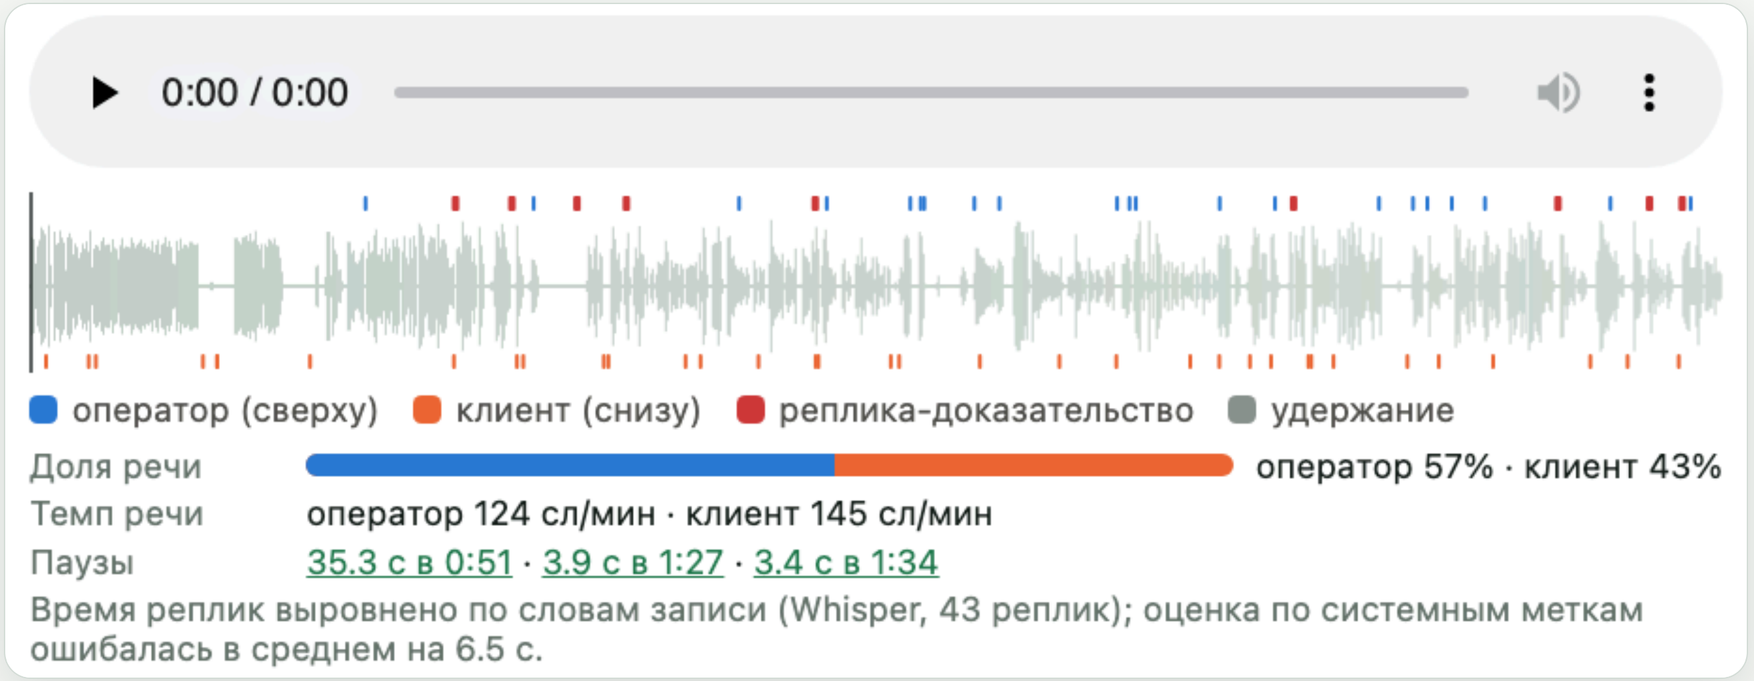
Звонки: 33% ошибок

шумный текст → Whisper-текст и разметка звонков

44 диалога: p = 0.19

активное обучение: размечать, где модели спорят

Звонки: слышим запись, а не только текст



Структура звонка + замеры по записи: **72.5%** → **76%**

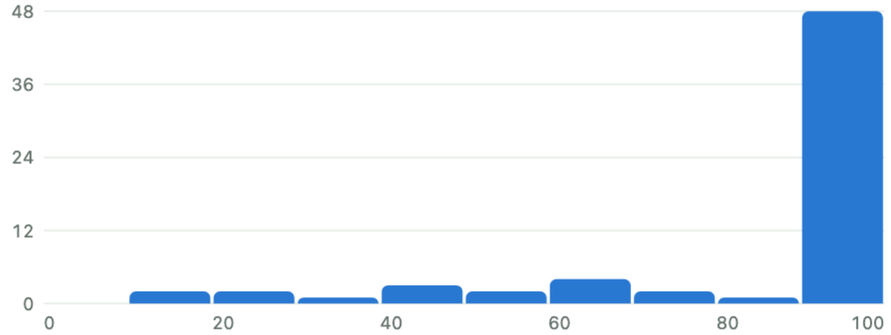
Вторая расшифровка и коррекция ASR — не помогли

Whisper слышит скрытые имена → только свой GPU

Весь набор — на одном экране

Оценено диалогов	Средний итог	Грубые ошибки	Требуют проверки	Апелляции	Стоимость набора
65 / 65	82.64 из 100	8 диалогов с флагом	8 критериев с сомнением	0 / 0 открыто / решено	$0.737 router(claude-sonnet-5-5, local:Qwen3.5-35B-A3B-GPTQ-Int4@sc5)

Распределение итоговых баллов



Исходы по критериям



Средний итог по языку и каналу



Требуют внимания

- ⚑ p1-en-013 — грубая ошибка
- ⚑ p1-en-014 — грубая ошибка
- ⚑ p1-kz-013 — грубая ошибка
- ⚑ p1-kz-015 — грубая ошибка
- ⚑ p1-ru-009 — грубая ошибка
- ⚑ p1-ru-022 — грубая ошибка
- ⚑ p1-ru-023 — грубая ошибка
- ⚑ p1-ru-029 — грубая ошибка
- p1-ru-018 — 12.50 баллов
- p1-ru-022 — 12.50 баллов
- p1-en-014 — 21 баллов
- p1-ru-026 — 26.25 баллов
- p1-kz-013 — 38.13 баллов

Дёшево. Быстро. Можно без облака.

$0.011

за диалог — все вызовы моделей, по фактическим токенам

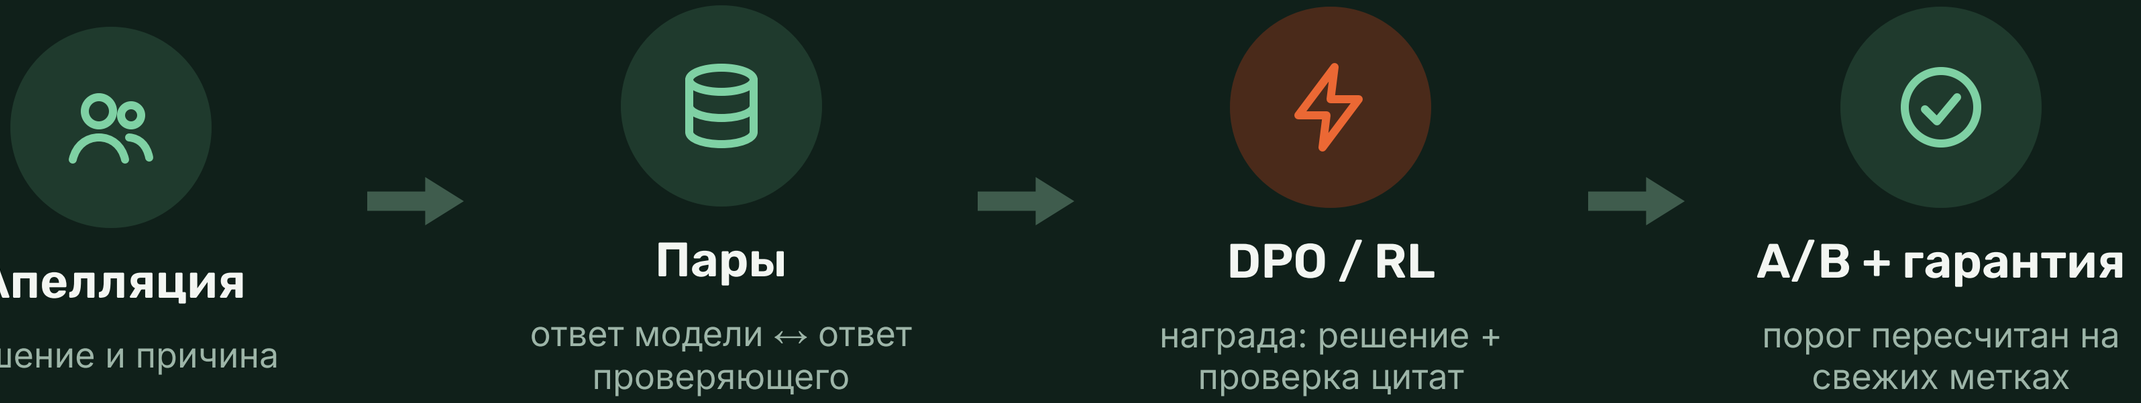
6 с

чтобы применить новый критерий — заново оценивается только он

$0

режим только на своём GPU: данные клиентов не уходят наружу

Дальше: модель учится на решениях проверяющих



Награду считает код — модель нельзя «уговорить». Обучаем свою модель на GPU: данные остаются внутри.

Готово к внедрению

Web Components без фреймворка — встраивается в Dynamics 365

Один слой данных — заменяется на Dataverse

Код, эксперименты и демо — github.com/AkhmadAssentay/cqa-freedom

Спасибо!